



模式识别与机器学习第四次作业

Transformer 复现与 Q、K、V 必要性对照

——基于标准 QKV 与 Shared K/V 注意力结构的比较

院/系名称： 自动化科学与电气工程学院

专业名称： 自动化

学生学号： 23373072

学生姓名： 田时承

目录

摘 要	2
1 研究背景与任务说明	2
2 Transformer 核心结构复现	2
2.1 整体模型结构	2
2.2 缩放点积注意力与多头注意力	2
2.3 位置编码、前馈网络与正则化	3
2.4 原论文结构与本实验复现范围	3
2.5 工程文件与调用关系	3
3 Q、K、V 必要性对照实验设计	4
3.1 研究问题与对照方案	4
3.2 合成键值检索数据集	4
3.3 实验参数设置	5
3.4 评价指标	5
4 实验结果与分析	6
4.1 验证集损失变化	6
4.2 验证集 Token Accuracy 变化	6
4.3 验证集 Exact Match 变化	7
4.4 测试集结果汇总	8
4.5 注意力热力图可视化分析	9
5 结论与不足	10
参考文献	11

摘要

本文围绕 Vaswani 等人在 2017 年提出的 Transformer 模型开展复现与模块必要性分析。在工程实现上，本文复现了编码器—解码器结构、多头注意力、缩放点积注意力、正弦位置编码、前馈网络、残差连接、层归一化、标签平滑以及 Noam 学习率调度等核心机制。针对“Q、K、V 是否需要分离建模”这一问题，本文设计标准 QKV 注意力与 Shared K/V 注意力的对照实验，并基于合成键值检索数据集进行 50 轮训练。结果表明，Shared K/V 模型在验证集最高 Exact Match 上达到 16.00%，略高于标准 QKV 的 15.25%；但在独立测试集上，标准 QKV 的 Token Accuracy 为 53.23%，Exact Match 为 13.88%，均高于 Shared K/V 的 52.28% 与 11.63%。注意力热力图进一步表明，两类模型均能形成非均匀的交叉注意力分布，但标准 QKV 在可视化样本中呈现出更清晰的重点区域聚焦。综合来看，取消 K 与 V 的独立投影后，模型仍具备学习能力，但测试集完整序列预测与泛化表现出现一定下降，支持 Q、K、V 功能解耦的必要性。

关键词：Transformer；注意力机制；QKV；Shared K/V；键值检索；对照实验

1 研究背景与任务说明

《Attention Is All You Need》提出了一种完全基于注意力机制的序列到序列模型 Transformer。该模型通过自注意力机制建立序列内部远距离依赖关系，避免循环神经网络按时间步串行计算带来的并行受限问题，并在机器翻译任务上取得了显著效果。原论文的核心结构由编码器、解码器、多头注意力、位置编码、前馈网络以及残差连接与层归一化组成。

本次作业包含两个任务：第一，完成 Transformer 主要结构的代码复现；第二，围绕注意力机制中的 Q、K、V 设计开展模块必要性实验。考虑到原论文的大规模机器翻译任务需要较多数据与计算资源，本文采用可控的合成键值检索任务，重点研究注意力结构中 K 与 V 分离建模的意义，而非直接复现原论文的 BLEU 分数。

键值检索任务能够将“通过 Query 与 Key 进行匹配、再读取 Value 输出结果”的过程显式化，与注意力机制的核心逻辑具有较高一致性。因此，该任务适合作为分析 Q、K、V 功能分工的控制实验。

2 Transformer 核心结构复现

2.1 整体模型结构

本工程采用编码器—解码器式 Transformer。编码器由若干层 EncoderLayer 叠加构成，每层包含多头自注意力子层和位置前馈网络子层；解码器由若干层 DecoderLayer 叠加构成，每层依次包含带因果掩码的自注意力、编码器—解码器交叉注意力以及位置前馈网络。各子层外均使用残差连接与 LayerNorm，从而提升深层网络训练稳定性。

2.2 缩放点积注意力与多头注意力

标准缩放点积注意力可写为： $\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) V$ 。其中，Q 表示 Query，负责表达“当前要查询什么”；K 表示 Key，负责与 Query 计算匹配程度；V 表示 Value，负责在注意力权重作用下输出实际信息。工程中将注意力扩展为多头形式，先将表示空间拆分为若干个头并行计算，再将各头结果拼接并映射回 d_{model} 维度。

多头注意力的优势在于，不同子空间中的注意力头可学习不同关系模式。在本实验中，虽然网络规模经过压缩，但标准 QKV 与 Shared K/V 两组模型均保留了多头注意力的基本结构，以确保对照实验聚焦于 K 与 V 是否共享投影，而非改变其他核心模块。

2.3 位置编码、前馈网络与正则化

由于 Transformer 不包含循环结构与卷积结构，模型本身无法直接感知序列顺序，因此工程中使用正弦—余弦位置编码，并将其与词嵌入相加。前馈网络采用两层线性变换与 ReLU 激活，完成逐位置的非线性变换。训练阶段进一步加入 Dropout、Label Smoothing 和梯度裁剪；优化器使用 Adam，并按照 Noam 学习率策略进行预热与衰减。

2.4 原论文结构与本实验复现范围

原论文中的 Transformer base 模型使用更大的结构参数，并在大规模机器翻译数据集上训练。本文的目标是复现结构逻辑并完成可运行的模块必要性实验，因此使用较小规模模型，以适配普通 CPU 环境并缩短迭代时间。

比较项目	原论文 base 结构	本实验设置
模型层数 N	6	2
d_model	512	128
注意力头数 h	8	4
d_ff	2048	256
位置编码	正弦—余弦	正弦—余弦
优化策略	Adam + Noam	Adam + Noam
实验任务	机器翻译	合成键值检索

表 1 原论文 Transformer base 与本实验复现设置对比

2.5 工程文件与调用关系

文件	功能
generate_dataset.py	生成合成键值检索数据集，可输出 CSV 与 XLSX 文件
train.py	训练单一模型，可选择 standard 或 shared_kv 模式
compare_experiment.py	依次训练两种模型，输出对比 CSV 与三张验证曲线

src/attention.py	实现标准 QKV 与 Shared K/V 多头注意力
src/model.py	实现编码器、解码器、完整 Transformer 及贪心解码
src/training.py	实现训练、验证、测试、checkpoint 保存与指标记录
visualize_attention.py	读取 checkpoint 后绘制注意力热力图，需单独运行

表 2 工程核心文件及功能说明

3 Q、K、V 必要性对照实验设计

3.1 研究问题与对照方案

为了考察 K 与 V 分离建模是否必要，本文设置两组模型。第一组为标准 QKV 模型，分别使用 W_Q 、 W_K 、 W_V 进行线性投影；第二组为 Shared K/V 模型，保留独立的 Q 投影，但将 K 与 V 合并为同一个投影，即 $K = KV$ ， $V = KV$ 。此时注意力计算可表示为： $\text{Attention_shared}(Q, KV) = \text{softmax}(Q(KV)^T / \sqrt{d_k}) KV$ 。该设计保持注意力的基本计算逻辑不变，但取消了 K 与 V 的独立表示能力。

从功能角度看，K 主要承担“匹配”的角色，V 主要承担“信息传递”的角色。若 K 与 V 使用同一组投影，模型需要让同一表示同时兼顾相似度判断与内容表达，可能会影响最终检索与生成效果。因此，本实验本质上是在检验“匹配空间”和“内容空间”是否有必要解耦。

3.2 合成键值检索数据集

实验采用自生成的键值检索任务。每条输入序列由若干组键值对和查询序列构成，模型需要根据查询顺序输出对应的 Value。该任务天然对应“匹配键—读取值”的注意力过程，因此适合用来分析 K 与 V 是否应当分离。

项目	内容
示例输入 src	K3 V7 K1 V4 K5 V2 <sep> Q1 Q5 Q3
映射关系	$K3 \rightarrow V7$, $K1 \rightarrow V4$, $K5 \rightarrow V2$
示例输出 tgt	V4 V2 V7

表 3 合成键值检索样本示例

在该数据格式中，K、V、Q、<sep> 等离散符号均被视作 token。训练过程中，模型需要从输入序列中识别键值映射，再按查询顺序给出对应的 Value 输出。评价指标中的 Token Accuracy 表示每个输出 token 的预测正确率，而 Exact Match 要求整条输出序列完全一致。

3.3 实验参数设置

参数	取值
数据划分	5000 / 800 / 800
词表大小	65
训练轮数 epochs	50
batch size	64
d_model	128
num_layers	2
num_heads	4
d_ff	256
dropout	0.1
warmup_steps	400
label_smoothing	0.1
grad_clip	1.0
seed	2026
设备	CPU

表 4 主要训练参数

3.4 评价指标

本文使用三个主要指标。Validation Loss 用于衡量验证集上模型预测分布与真实标签之间的差异；Token Accuracy 统计输出序列中单个 token 的预测正确率；Exact Match 则要求整条输出序列完全预测正确，属于更严格的序列级评价指标。由于测试阶段需要评估真实生成能力，本文重点关注测试集 Token Accuracy 与 Test Exact Match。

4 实验结果与分析

4.1 验证集损失变化

图 1 显示，两种模型的 Validation Loss 均随训练轮数增加而整体下降，说明两种结构都能够学习键值检索任务。标准 QKV 的最低验证损失为 1.6216（第 47 轮），Shared K/V 的最低验证损失为 1.6232（第 27 轮）。两条曲线在后期均趋于平台，表明模型逐渐进入收敛阶段。




图 1 标准 QKV 与 Shared K/V 的验证集损失对比

4.2 验证集 Token Accuracy 变化

图 2 展示了两种模型在验证集 Token Accuracy 上的变化趋势。随着训练推进，两组模型均由较低的初始准确率逐步提升，说明模型对键值检索映射的学习不断增强。标准 QKV 的最高验证集 Token Accuracy 为 55.86%（第 46 轮），Shared K/V 的最高值为 55.65%（第 45 轮）。二者在单 token 预测层面的差距较小，但标准 QKV 的峰值略高。




图2 标准 QKV 与 Shared K/V 的验证集 Token Accuracy 对比

4.3 验证集 Exact Match 变化

图3展示了序列级完全匹配率（Exact Match）的验证集变化趋势。该指标更关注整条输出序列是否完全正确，因此波动幅度相对更大。Standard QKV 的最佳验证集 Exact Match 为 15.25%（第 47 轮），Shared K/V 的最佳验证集 Exact Match 为 16.00%（第 27 轮）。Shared K/V 在验证集单点最优值上略高，但该优势并未转化为测试集上的更优泛化表现。




图 3 标准 QKV 与 Shared K/V 的验证集 Exact Match 对比

4.4 测试集结果汇总

模型	Best Val Exact	Test Loss	Test Token Acc	Test Exact Match
Standard QKV	15.25%	1.6596	53.23%	13.88%
Shared K/V	16.00%	1.6530	52.28%	11.62%

表 5 两种注意力结构的测试集结果对比

由表 5 可知，Shared K/V 的 Test Loss 为 1.6530，略低于标准 QKV 的 1.6596；但在更具任务解释性的测试集准确率指标上，标准 QKV 的 Test Token Accuracy 为 53.23%，高于 Shared K/V 的 52.28%，提升 0.95 个百分点；标准 QKV 的 Test Exact Match 为 13.88%，高于 Shared K/V 的 11.62%，提升 2.25 个百分点。

这一结果说明，K 与 V 共享投影后，模型仍然可以完成注意力计算并学习一定的映射关系，但由于“匹配表示”和“内容表示”被压缩到同一空间，测试集上的完整序列预测能力有所减弱。因此，本实验支持 Transformer 中 Q、K、V 分离建模具有合理性。需要注意的是，Shared K/V 结构同时减少了一个独立投影矩阵，其参数自由度相较标准 QKV 略低，故本实验更准确的结论应表述为：取消 K 与 V 的独立投影，会对该键值检索任务的测试集表现产生一定不利影响。

4.5 注意力热力图可视化分析

为进一步观察两类结构在交叉注意力中的信息关注模式，本文在已训练 checkpoint 上调用 `visualize_attention.py`，选取同一测试样本绘制 Decoder Cross-Attention Heatmap。该样本的源序列为：K18 V5 K11 V7 K8 V10 <sep> Q8 Q18 Q11 <eos>，查询顺序对应的目标输出为 V10 V5 V7。热力图横轴表示源序列 token，纵轴表示解码端输入 token，颜色越亮代表注意力权重越大。




图 4 Standard QKV 模型的 Decoder Cross-Attention Heatmap

从图 4 可见，标准 QKV 模型在部分解码位置上呈现出较明显的注意力集中区域。例如，在输出序列后段，模型对 Q8、Q18、Q11 这三个查询符号分配了较高的注意力权重，说明解码器会主动回看输入中的查询区域，再结合前文键值对信息生成相应的 Value。该现象表明标准 QKV 结构能够形成有区分度的交叉注意力分布。




图 5 Shared K/V 模型的 Decoder Cross-Attention Heatmap

图 5 显示，Shared K/V 模型同样能够在查询区域形成较高响应，说明共享 K/V 并不会使注意力机制完全失效。不过，与标准 QKV 的示例图相比，Shared K/V 在若干位置上的响应分布更为分散，部分注意力同时落在键值区与查询区。这与其测试集 Exact Match 略低的结果相呼应：当匹配与内容表示共享同一投影空间时，模型仍能学习检索行为，但其信息分配可能不如独立 K/V 表示清晰。

需要说明的是，热力图只反映单一样本的可视化结果，不足以单独构成统计性结论；其主要作用是为表 5 中的量化结果提供直观解释。综合量化指标与可视化现象，标准 QKV 在本实验任务中表现出更优的测试集完整序列预测能力。

5 结论与不足

本文完成了 Transformer 关键结构的工程复现，并以 Q、K、V 分离建模的必要性为切入点，设计了标准 QKV 与 Shared K/V 的对照实验。在合成键值检索任务上，两种模型均能够收敛并学习查询—返回关系；但在独立测试集上，标准 QKV 模型的 Token Accuracy 与 Exact Match 均优于 Shared K/V，说明 K 与 V 的功能解耦有助于提升完整序列预测与泛化能力。

本实验仍存在三点限制：

- (1) 数据集为合成任务，能够突出检索机制，但与真实机器翻译仍有差距。

(2) 当前对照实验基于单一随机种子，若要进一步增强结论稳健性，可进行多随机种子重复训练并报告均值与标准差。

(3) Shared K/V 变体在共享表示的同时也减少了独立投影参数，后续可引入参数量更加严格对齐的结构，进一步检验“表示共享”本身带来的影响。

参考文献

- [1] Vaswani A., Shazeer N., Parmar N., et al. Attention Is All You Need[C]// Advances in Neural Information Processing Systems. 2017.
- [2] He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition[C]// CVPR. 2016.
- [3] Ba J. L., Kiros J. R., Hinton G. E. Layer Normalization[EB/OL]. arXiv:1607.06450, 2016.
- [4] Kingma D. P., Ba J. Adam: A Method for Stochastic Optimization[C]// ICLR. 2015.